Predicción temprana de brotes de dengue en Bucaramanga mediante machine learning

Araque Villamizar, R. y Paipa Bautista, D. A. (2026). Trabajo de grado, Maestría en Análisis de Datos y Sistemas Inteligentes, Universidad Santo Tomás, Bucaramanga. Las citas siguen APA 7 e indican la página del documento.

---

1. Problemática

El dengue es endémico en Bucaramanga y produce brotes recurrentes con una alta proporción de hospitalizaciones. Sin embargo, el municipio no tiene herramientas para anticiparlos, así que las medidas de control se activan cuando el pico de contagios ya está en curso. El trabajo propone un modelo de machine learning que prediga los brotes con una a cuatro semanas de antelación (Araque Villamizar y Paipa Bautista, 2026, pp. 8, 16-17).

Entre 2015 y 2022 el municipio notificó 10.259 casos al SIVIGILA. La tasa de hospitalización fue del 26,6 % y algunos picos superaron los 100 casos semanales (pp. 14-15, 17). Esta carga se reparte de forma desigual entre las 17 comunas de la ciudad, lo que según los autores indica que factores ambientales, socioeconómicos y geográficos condicionan la transmisión (p. 15). El problema operativo es la gestión reactiva. La fumigación, la eliminación de criaderos (descacharrización) y el refuerzo hospitalario se despliegan tarde, lo que genera morbilidad evitable, presión sobre urgencias y un uso tardío e ineficiente de los recursos de control vectorial (p. 16). De ahí surge la pregunta de investigación: cómo usar los datos históricos de dengue de la ciudad, integrados con variables climáticas, geográficas y sociodemográficas, para predecir brotes y emitir alertas tempranas (p. 17).

La justificación científica es una brecha de escala. Los antecedentes más cercanos trabajan a nivel nacional o departamental en Colombia (Zhao et al., 2020) o a nivel estatal en Brasil (Chen y Moraga, 2025; Sebastianelli et al., 2024). Ninguno calibra un modelo para la escala intraurbana de una ciudad intermedia colombiana, donde los agregados nacionales ocultan las diferencias entre comunas (pp. 16-17). La revisión sistemática siguió el protocolo PRISMA en Web of Science y Scopus: de 559 registros quedaron 428 únicos, 100 se leyeron a texto completo y 15 se seleccionaron (p. 28). De esa revisión los autores extraen 13 brechas en seis categorías y priorizan seis de ellas:

- B1: ausencia de análisis por comuna en Bucaramanga.
- B3: falta de comparación de algoritmos modernos con datos municipales.
- B4: falta de un método de integración multimodal.
- B6: transferibilidad entre contextos.
- B7: ausencia de datos recientes.
- B8: desconexión entre los modelos y la operación sanitaria (pp. 31-34).

El trabajo plantea tres objetivos específicos (p. 18):

1. Caracterizar los patrones temporales de la incidencia y su relación con el clima.

2. Determinar la distribución espacial del riesgo entre comunas.
3. Comparar Random Forest, XGBoost y LSTM frente a dos líneas base: un modelo naïve estacional y ARIMA.

---

2. Dataset

El conjunto de datos central son los 10.259 casos de dengue de Bucaramanga notificados al SIVIGILA entre 2015 y 2022, cruzados con series climáticas del IDEAM. El diseño también incluía imágenes satelitales y datos censales, pero el modelado final usó solo los casos y el clima de 2015–2020. La razón es que las series de temperatura y humedad del IDEAM terminan en diciembre de 2020 (Araque Villamizar y Paipa Bautista, 2026, pp. 42, 65-66, 82).

La fuente epidemiológica son las fichas de notificación del SIVIGILA para los eventos 210 (dengue sin signos de alarma), 220 (con signos de alarma) y 580 (dengue grave). Cada registro incluye:

- fecha de inicio de síntomas y fecha de notificación;
- semana epidemiológica y año;
- clasificación final del caso e indicador de hospitalización;
- barrio y comuna de residencia;
- sexo, edad y tipo de aseguramiento;
- resultados de laboratorio (p. 42).

Los datos son públicos, se obtienen de datos.gov.co y de reportes del INS, y no contienen información personal identificable (p. 42). El alcance se limita al área urbana y sus 17 comunas, sin el área metropolitana, y excluye datos entomológicos porque no existen sistematizados para el periodo (pp. 19-20). La Tabla 1 de los autores resume las cuatro fuentes previstas (p. 46). La última columna de la tabla siguiente se agrega aquí a partir de lo que reconocen en sus limitaciones:

Fuente	Variables	Resolución	¿Llegó al modelo final?
SIVIGILA (INS)	Casos, clasificación clínica, hospitalización, barrio/comuna	Por caso → semanal	Sí
IDEAM	Temperatura mín/máx/media, precipitación, humedad relativa	Diaria → semanal	Sí (hasta dic. 2020)
Sentinel-2 (ESA)	NDVI, cuerpos de agua, temperatura superficial	Mensual, 10 m	No de forma efectiva (p. 82)
DANE (Censo 2018)	Densidad, estrato, NBI, hacinamiento, cobertura de servicios	Estática por comuna	No de forma efectiva (pp. 82-83)

Varias restricciones prácticas moldearon el dataset real:

- **Ventana efectiva:** el corte del IDEAM redujo la ventana a 2015–2020, es decir, unas 313 semanas (pp. 66, 77).
- **Estrato socioeconómico:** tiene un alto porcentaje de registros vacíos en el SIVIGILA, por lo que no se pudo usar como predictor (p. 83).
- **Geocodificación:** cerca del 7 % de los casos no tiene comuna asignada (p. 83).
- **Subregistro:** la vigilancia es pasiva, de modo que la magnitud real de la transmisión puede estar subestimada (p. 83).

En la práctica, el dataset modelado es una serie semanal de casos con sus rezagos y variables climáticas rezagadas, más que la matriz multimodal completa que anuncian la introducción y el resumen.

---

3. Pipeline

El pipeline sigue el proceso CRISP-DM adaptado a salud pública. Se organiza en cinco capas secuenciales: recolección, preprocesamiento, ingeniería de características, modelado comparativo y sistema de alerta. Su lógica es convertir registros individuales de casos y series climáticas diarias en una matriz semanal de predictores, entrenar cinco modelos con una partición temporal estricta y traducir la mejor predicción en un semáforo de alerta por comuna (Araque Villamizar y Paipa Bautista, 2026, pp. 12, 37, 52). Los autores resumen el flujo así (p. 56):

```
None
Datos brutos → Limpieza → Agregación semanal/comunal →
Integración multimodal
→ Feature engineering → Dataset final (semana × comuna ×
variables)
```

3.1 Encuadre metodológico

Los autores definen la investigación como aplicada, cuantitativa y de alcance explicativo-predictivo. Es explicativa porque busca identificar los determinantes de los brotes y predictiva porque su producto es un pronosticador. No manipula variables: modela datos observacionales históricos con un diseño retrospectivo (pp. 37-38). La unidad de análisis es el caso notificado, agregado por semana epidemiológica y comuna (p. 38).

El trabajo se divide en cinco fases con una duración estimada de 20 a 24 semanas: análisis exploratorio, integración de datos, desarrollo de modelos, evaluación y prototipo (pp. 38-42). Cada fase corresponde a una capa de la arquitectura (Tabla 3, pp. 55-56). La implementación usa Python 3.10, Jupyter y Git. Las bibliotecas son pandas, numpy y geopandas para manipulación; scikit-learn, xgboost y TensorFlow/Keras para modelado; statsmodels para ARIMA y la prueba de Diebold-Mariano; shap para interpretabilidad; y earthengine-api para las imágenes satelitales (Tabla 4, pp. 59-60).

3.2 Capa 1: recolección e integración de fuentes

Esta capa centraliza la ingesta de las cuatro fuentes (pp. 52-53):

- **SIVIGILA:** aporta los registros de los eventos 210, 220 y 580 con variables demográficas, clínicas, temporales y georreferenciadas.
- **IDEAM:** aporta series diarias de temperatura mínima, máxima y media, precipitación acumulada y humedad relativa de las estaciones del área metropolitana.
- **DANE:** aporta indicadores del Censo 2018 por comuna.
- **Sentinel-2:** el NDVI se calcula en Google Earth Engine como (NIR − RED)/(NIR + RED). Se procesan escenas mensuales a 10 m con menos de 20 % de nubosidad y se exportan como CSV con valores medios por polígono de comuna (pp. 44-45, 47).

Los autores justifican cada fuente por su carácter oficial y por su vínculo biológico o socioeconómico con el vector. La temperatura determina la velocidad del desarrollo larval y la tasa de picadura. La lluvia crea criaderos temporales. Los estratos bajos tienen peores condiciones de almacenamiento de agua y mayor hacinamiento (pp. 43, 45).

3.3 Capa 2: preprocesamiento y homologación

El objetivo de esta capa es llevar todas las fuentes a una resolución común: semanal en el tiempo y por comuna en el espacio (p. 53). Cada fuente se transforma de manera distinta:

- **Casos:** los registros del SIVIGILA se agregan por semana epidemiológica y comuna. Para cada celda se calcula el conteo de casos, la proporción de hospitalizados y la distribución por clasificación clínica.
- **Clima:** los datos diarios del IDEAM pasan a semanales con el promedio para temperatura y humedad, y con la suma para la precipitación.
- **Variables censales:** como cambian lentamente, se replican sin cambios en cada semana.
- **NDVI:** al ser mensual, se interpola linealmente a resolución semanal.

El resultado teórico es un panel de unos 8 años × 52 semanas = 416 semanas (p. 53).

El Apéndice A.1 muestra la implementación (pp. 89-90). Primero filtra los registros por el código DIVIPOLA de Bucaramanga (68001). Luego convierte la fecha de notificación en semana y año, agrupa por año, semana y comuna para contar casos y hospitalizados, y une la tabla resultante con el clima semanal mediante un *left join* por año y semana. Los autores representan este flujo en la p. 60. Por el corte del IDEAM, el panel efectivo se redujo a 2015–2020 (pp. 48, 65-66).

3.4 Análisis exploratorio (Fase 1)

Antes de modelar, la metodología prevé un análisis exploratorio con estos componentes (pp. 38-39):

- estadísticas descriptivas, series de tiempo y mapas de calor por semana y comuna;
- tasas de incidencia ajustadas por población e identificación de los años epidémicos;
- prueba de Dickey-Fuller para estacionariedad y descomposición STL para separar tendencia, estacionalidad y residuo;

- correlación cruzada (CCF) entre casos y clima para encontrar los rezagos óptimos.

Esta fase es la que alimenta el diseño de las variables predictoras. En la ejecución, la CCF se evaluó para rezagos de 0 a 16 semanas (p. 68).

3.5 Capa 3: ingeniería de características

Esta capa construye tres grupos de predictores (pp. 53-54).

Variables climáticas rezagadas. Para cada variable climática se generan rezagos de 1 a 12 semanas. El rango se apoya en el ciclo biológico de *Aedes aegypti* documentado por la literatura (pp. 43-44):

Variable	Rezago	Justificación biológica
Temperatura diurna (media y máxima)	6 a 8 semanas	Desarrollo larval (1-2 semanas) + incubación extrínseca del virus (2-3) + transmisión activa (2-3)
Temperatura mínima	4 a 6 semanas	Efecto sobre la supervivencia del adulto
Precipitación	4 a 8 semanas	Maduración de criaderos; el exceso de lluvia puede arrastrarlos (efecto de dilución)
Humedad relativa	4 a 12 semanas	Prolonga la vida del adulto y la supervivencia larval
NDVI	2 a 6 semanas	Microhábitats húmedos favorables a criaderos

Los rezagos finales se eligen con valores SHAP calculados sobre los pliegues de validación temporal del periodo de entrenamiento, porque no existe un conjunto independiente de 2021 (p. 54). Para manejar la colinealidad entre semanas consecutivas, los autores proponen modelos de retardo distribuido no lineal (DLNM) y SHAP, que consideran superiores a la correlación cruzada simple (p. 44).

Estrategia diferenciada según el modelo. Los modelos tabulares (Random Forest y XGBoost) usan un bloque corto de 4 a 6 rezagos por variable; Lober et al. (2024) usan 5. La colinealidad se controla con la regularización L1/L2 de XGBoost y con la selección aleatoria de variables de Random Forest. La LSTM, en cambio, recibe una ventana deslizante de 12 semanas, y los rezagos climáticos se filtran antes con SHAP o una técnica de componentes para no saturar la red con información redundante (p. 50).

Variables de tendencia y estacionalidad. Incluyen medias móviles de 4, 8 y 12 semanas, indicadores binarios de temporada de lluvias y una codificación cíclica de la semana epidemiológica. Esta última usa dos variables, $\text{sen}(2\pi \cdot \text{semana}/52)$ y $\cos(2\pi \cdot \text{semana}/52)$, para que la semana 52 quede contigua a la semana 1 (p. 54; Apéndice A.2, pp. 90-91).

Variables espaciales estáticas. Son la densidad poblacional, la proporción de hogares de estratos 1 y 2, el índice de necesidades básicas insatisfechas (NBI) y la cobertura de acueducto y alcantarillado (p. 54).

Variables objetivo. La matriz final tiene entre 45 y 55 columnas y define dos objetivos (p. 56):

- regresión: número de casos en la semana $t+h$, con h de 1 a 4 semanas;
- clasificación: indicador binario que vale 1 cuando los casos de $t+h$ superan el percentil 75 histórico de la comuna.

En la ejecución reportada, la matriz incluyó rezagos de casos (1 a 12 semanas), rezagos climáticos (1 a 12), medias móviles y la codificación seno–coseno (p. 69).

3.6 Capa 4: modelado

Partición temporal. Los datos se dividen cronológicamente, nunca al azar, para evitar fuga de información del futuro. El entrenamiento usa 2015–2018 y la prueba usa 2019–2020. Los hiperparámetros se ajustan con validación cruzada temporal (TimeSeriesSplit) dentro del entrenamiento, de modo que ningún dato de prueba interviene en el ajuste (pp. 47-48). Los autores destacan que el conjunto de prueba contiene la epidemia más intensa de la serie (2019). Según ellos, esto convierte una restricción de datos en una prueba exigente, porque evalúa los modelos justo en el escenario que más importa anticipar (p. 66).

Líneas base. Se usan dos referencias. El modelo naïve estacional repite el valor de la temporada anterior. ARIMA modela la autocorrelación de la serie (p. 36).

Random Forest. Se configura como regresor y como clasificador. Los rangos de búsqueda son:

- 100 a 500 árboles;
- profundidad máxima de 10 a 40;
- mínimo de muestras por división de 5 a 30;
- variables por división `sqrt` o `log2`.

La búsqueda se hace con RandomizedSearchCV y TimeSeriesSplit (p. 57). La configuración elegida para h = 1 fue de 300 árboles, sin profundidad máxima y con la mitad de las variables por división (p. 72).

XGBoost. Los rangos de búsqueda son:

- tasa de aprendizaje de 0,01 a 0,1;
- profundidad de 3 a 10;
- submuestreo de filas de 0,6 a 1,0;
- regularización L1 de 0 a 1 y L2 de 1 a 10;
- *early stopping* de 50 rondas sobre los pliegues temporales.

Los autores también valoran que XGBoost maneja de forma nativa los valores faltantes del clima (p. 57). La configuración elegida fue de 400 árboles, profundidad 5 y tasa de aprendizaje 0,1 (p. 72).

LSTM. Recibe tensores de forma (muestras, 12 semanas, variables). La arquitectura es la siguiente:

1. una capa LSTM de 128 unidades que devuelve secuencias, con dropout de 0,2;
2. una capa LSTM de 64 unidades, con dropout de 0,2;
3. una capa densa de 32 neuronas con activación ReLU;
4. una salida de una neurona, lineal para regresión o sigmoide para clasificación.

El optimizador es Adam con tasa inicial de 0,001, que se reduce automáticamente si la pérdida no mejora en 5 épocas. La función de pérdida es el error cuadrático medio. El entrenamiento dura un máximo de 150 épocas con *early stopping* de paciencia 15 (p. 58). Todos los experimentos usan la semilla aleatoria 42 (p. 65).

3.7 Evaluación

Los cinco modelos se evalúan sobre el mismo conjunto de prueba, los mismos horizontes y las mismas métricas (pp. 58-59).

Métricas de regresión (p. 48):

- MAE: error absoluto en número de casos.
- RMSE: penaliza más los errores grandes, que son los típicos de un brote.
- MAPE: error relativo.
- MASE: error escalado respecto al naïve estacional. Un valor menor que 1 significa que el modelo supera al naïve. Los valores de referencia de la literatura son MASE ≈ 0,55–0,60 para modelos de árboles y MAPE ≈ 24 % para LSTM a 4 semanas (pp. 48-49).

Métricas de detección de brotes. Se usan precisión, recall, F1 y AUC-ROC con el umbral del percentil 75. Los autores dan más peso al recall, porque no detectar un brote cuesta más que emitir una falsa alarma (p. 49). En la ejecución, el umbral fue el percentil 75 del periodo de entrenamiento, equivalente a 41 casos semanales (p. 73).

Pruebas complementarias:

- la prueba de Diebold-Mariano bilateral entre pares de modelos ($\alpha = 0{,}05$), para saber si las diferencias de error son estadísticamente significativas (pp. 50-51, 59);
- la importancia por permutación, los valores SHAP y la correlación cruzada para interpretar los modelos (p. 49);
- un análisis de equidad, con métricas desagregadas por quintil de NBI, para detectar sesgos entre comunas pobres y ricas (p. 51).

3.8 Capa 5: sistema de alerta DengueAlert-BGA

El prototipo tiene tres módulos (pp. 62-65).

Módulo 1: actualización. Ejecuta cada semana el preprocesamiento: incorpora los nuevos casos del SIVIGILA, el clima del IDEAM y el NDVI mensual, y regenera el panel de datos (p. 62).

Módulo 2: predicción. Usa XGBoost. Sus pasos, según el pseudocódigo de los autores, son (pp. 63-64):

1. cargar el modelo entrenado;
2. construir las variables: rezagos de casos de 1 a 8 semanas, media móvil de 4 semanas y clima rezagado;
3. predecir para cada horizonte de 1 a 4 semanas;
4. clasificar el nivel de riesgo;
5. calcular los valores SHAP que explican la alerta;
6. enviar los resultados al tablero.

La incertidumbre se estima con *bootstrap* en Random Forest y XGBoost, y con Monte Carlo Dropout en la LSTM. Con esa incertidumbre se calcula la probabilidad de superar el umbral de brote de cada comuna (p. 63).

Módulo 3: semáforo y visualización. Convierte esa probabilidad en cuatro niveles (Tabla 5, p. 64):

Nivel	Probabilidad de brote	Acción sugerida
Verde	menor que 25 %	Vigilancia rutinaria
Amarillo	25–50 %	Reforzar vigilancia y comunicación comunitaria
Naranja	50–75 %	Jornadas de control vectorial focalizadas
Rojo	mayor que 75 %	Activar el plan de contingencia municipal

El tablero se construye en Streamlit, con mapas en Folium. Muestra un mapa de comunas coloreado por nivel de alerta, la serie histórica con la predicción a 4 semanas y sus bandas de confianza, indicadores clave y una tabla de prioridades de intervención (pp. 47, 55, 64-65).

Los autores reconocen tres limitaciones del prototipo: la actualización es manual porque no existe una API pública, el NDVI mensual introduce imprecisión en la escala semanal y el sistema no está integrado con los sistemas del municipio (p. 65).

---

4. Resultados

Los tres modelos competitivos (ARIMA, Random Forest y XGBoost) superaron ampliamente al modelo ingenuo. Su MASE estuvo entre 0,57 y 0,67, frente a 2,27 del naïve, y distinguieron las semanas de brote con un AUC de 0,92 a 0,95. Sin embargo, el modelo más exacto fue ARIMA, no uno de machine learning, y la LSTM fracasó por falta de datos (Araque Villamizar y Paipa Bautista, 2026, pp. 73-77).

Modelo	MAE	RMSE	MAPE %	MASE	F1	AUC

ARIMA	11,06	15,21	46,2	0,57	0,82	0,95
Random Forest	12,58	17,22	58,6	0,65	0,76	0,93
XGBoost	12,91	17,89	56,3	0,67	0,72	0,92
LSTM	18,96	26,22	71,7	0,98	0,08	0,74
Naïve estacional	43,74	50,09	392,1	2,27	0,00	0,23

Promedio de los horizontes 1 a 4 semanas, conjunto de prueba 2019–2020 (Tabla 7, p. 73).

Patrones temporales. La serie muestra tres ondas epidémicas, en 2015, 2016 y 2019; la última alcanzó cerca de 110 casos en una semana. Entre ellas, 2017 y 2018 fueron años de baja transmisión, un patrón típico de las arbovirosis que los autores atribuyen al agotamiento de susceptibles y a la rotación de serotipos (p. 66). El perfil estacional concentra la carga en el primer y segundo trimestre del año. La descomposición STL separa una estacionalidad anual estable de una tendencia dominada por las ondas epidémicas (p. 67). En la correlación cruzada, la temperatura mostró la mayor asociación ($r = 0,36$ con 7 semanas de rezago). La humedad tuvo una relación inversa débil hacia las 16 semanas ($r = -0,20$) y la precipitación una señal aún menor (p. 68).

Distribución espacial. San Francisco (1.136 casos), Centro (1.061) y Oriental (874) concentran el 32,4 % de los casos (Tabla 6, p. 70). El ranking de comunas es estable año a año, pero todas amplifican sus casos al mismo tiempo en los años epidémicos. Los autores lo interpretan como una estructura espacial fija sobre la que actúa un disparador climático común a toda la ciudad (p. 71). La tasa de hospitalización varía entre 18,5 % (García Rovira) y 31,2 % (Norte), lo que podría reflejar diferencias de acceso a la atención (p. 71).

Comparación de modelos. Todos los modelos pierden exactitud al alargar el horizonte de predicción (Tabla 8, p. 73):

- ARIMA pasa de MASE 0,42 a 0,74 y su F1 baja de 0,88 a 0,74.
- XGBoost tiene el mejor F1 a una semana (0,89), pero cae a 0,55 a cuatro semanas.
- La LSTM supera el valor 1 de MASE desde $h = 3$ y su F1 llega a cero.

La prueba de Diebold-Mariano a una semana arroja dos resultados (p. 74). Primero, XGBoost supera al naïve de forma contundente (estadístico $-10,61$; $p < 0,001$). Segundo, ARIMA supera a XGBoost de forma significativa (estadístico 2,49; $p = 0,013$).

En cuanto a interpretabilidad, la importancia por permutación (Random Forest) y los valores SHAP (XGBoost) coinciden: el poder predictivo se concentra en los casos de la semana anterior y en su media móvil de 4 semanas, seguidos por la componente estacional. Entre las variables climáticas, las más informativas son la temperatura rezagada y la precipitación acumulada a seis semanas (pp. 75-77). Los autores atribuyen el fracaso de la LSTM a que 313 semanas son insuficientes para una red profunda (p. 77).

---

5. Conclusiones

Los autores concluyen que es posible anticipar brotes de dengue en Bucaramanga usando solo datos públicos locales. Eligen XGBoost como motor del prototipo DengueAlert-BGA, aunque ARIMA fue más exacto, porque XGBoost permite incorporar variables externas y explicar cada alerta (Araque Villamizar y Paipa Bautista, 2026, pp. 79, 81-82).

El hallazgo central es que el SIVIGILA y las estaciones del IDEAM contienen una señal predictiva que durante años se usó solo de forma descriptiva (p. 79). Según los autores, esto lleva el antecedente de Zhao et al. (2020) desde la escala departamental hasta la municipal (pp. 79-80). La elección de XGBoost se sustenta en tres argumentos de valor operativo, no de exactitud (pp. 81-82):

1. Integra variables exógenas como el clima, los rezagos y las medias móviles, mientras que ARIMA solo usa la historia de la propia serie.
2. Es interpretable mediante SHAP, lo que permite a la Secretaría de Salud justificar y focalizar sus intervenciones.
3. Es extensible: puede incorporar nuevas fuentes, como índices entomológicos o NDVI, sin cambiar de arquitectura.

ARIMA se conserva como línea base de referencia. Los autores dan por cumplidos los tres objetivos específicos y el general (pp. 78-81).

Las limitaciones declaradas son importantes (pp. 82-83):

- el clima termina en 2020;
- la muestra es demasiado pequeña para aprendizaje profundo;
- el NDVI y los datos del DANE no se incorporaron de forma efectiva;
- el estrato socioeconómico está incompleto;
- alrededor del 7 % de los casos no tiene comuna y existe subregistro;
- la validación cubre un solo año epidémico, por lo que no está garantizado que el modelo generalice ante epidemias atípicas.

Como trabajo futuro proponen (pp. 83-84):

- poner en operación el sistema para la Secretaría de Salud, al estilo de InfoDengue en Brasil;
- extender las series del IDEAM o reemplazarlas por reanálisis climático ERA5;
- incorporar el DANE y el NDVI en modelos bayesianos espaciotemporales, como INLA o ArboAlvo;
- probar modelos híbridos que combinen el componente autorregresivo de ARIMA con modelos de árboles;
- validar la transferibilidad al área metropolitana y a Santander.