Machine learning con clima anticipa brotes de dengue de 1 a 4 semanas

Araque y Paipa (2026) · Tesis de maestría, Universidad Santo Tomás · Bucaramanga, Colombia

1 Problema

Bucaramanga tiene brotes recurrentes de dengue (26,6 % de hospitalización), pero ninguna herramienta que los anticipe. ¿Se pueden predecir con datos públicos?

2 Datos

10 259 casos · **313** semanas · **17** comunas

SIVIGILA (casos) + IDEAM (temperatura, lluvia, humedad), semanal 2015–2020.

3 Método (CRISP-DM)

1. Casos por semana + clima
2. Rezagos 0–16 sem, medias móviles
3. Brote = sobre percentil 75
4. Train 2015–18 · Test 2019–20
5. 5 modelos, horizonte 1–4 sem

4 Información que más pesa (SHAP)

- **Casos de la semana anterior** — historial reciente
- **Media móvil de 4 semanas** — tendencia de casos
- **Temperatura** — t − 7 semanas (r = 0,36)
- **Lluvia acumulada** — ventana de 6 semanas

Los casos pasados pesan más que el clima. NDVI y DANE no entraron al final.

5 Resultado (test 2019–2020)

Modelo	MASE	F1	AUC
ARIMA	0,57	0,82	0,95
Random Forest	0,65	0,76	0,93
XGBoost ★	**0,67**	**0,72**	**0,92**
LSTM	0,98	0,08	0,74
Naïve estacional	2,27	0,00	0,23

ML y ARIMA reducen el error a menos de 2/3 del naïve ($p < 0,001$).

ARIMA gana en exactitud, pero eligen **XGBoost**: usa el clima y se explica con SHAP.

LSTM falla: 313 semanas son pocos datos.

Nuestra investigación (leishmaniasis, selva del Perú): es casi el mismo diseño. Casos de notificación por semana (CDC-MINSA ≈ SIVIGILA) + clima con rezagos, brote = percentil 75, split temporal, y ARIMA como línea base obligatoria frente a XGBoost.